

# Zadanie 1: Korpusy anotowane oraz osadzenia słów i tekstów

Opracowanie: dr inż. Arkadiusz Janz, dr hab. inż. Maciej Piasecki prof. PWR

Zmodyfikowane: Konrad Kiełczyński

Czas wykonania: 2 tygodnie (oddanie lab 3)

Korpus językowy jest zbiorem tekstów, który stanowi podstawowy zasób praktycznie w każdym zadaniu związanym z przetwarzaniem języka naturalnego. Przy pomocy wielkich korpusów można budować ogólne reprezentacje językowe, szukać kontekstów występowania słów, a także analizować specyficzne konstrukcje składniowe i semantyczne w danym języku (lub językach - w przypadku korpusu wielojęzycznego). Mniejsze korpusy często są także ręcznie wzbogacane o dodatkowe metadane, dzięki czemu możliwe jest wykorzystanie takich danych w uczeniu maszynowym do zadań klasyfikacji całych dokumentów, zdań, a także fraz, czy też pojedynczych słów. Elektroniczne wersje korpusów tekstowych służą do prowadzenia badań nad językiem, tworzenia słowników, wyszukiwarek, a także systemów tłumaczenia maszynowego, określania stylu literackiego, rozpoznawania wydźwięku i emocji, ujednoznaczniania znaczeń słów, wydobywania nazw własnych i wielu innych zastosowań.

Często wyzwaniem dla badaczy jest określenie składu korpusu, czyli takiego doboru tekstów, by były one reprezentatywne z perspektywy konkretnego problemu do rozwiązania. W kontekście budowania wielkich, ogólnych modeli językowych, istotne jest zebranie jak największej liczby tekstów z różnych źródeł, dziedzin oraz stylów wypowiedzi (książki, artykuły, blogi, komentarze, recenzje, itp.). Często jednak problemy są bardzo specyficzne i ukierunkowane dziedzinowo, np.:

- detekcja fałszywych wiadomości dotyczących COVID-19,
- rozpoznawanie wydźwięku opinii pacjentów o lekarzach,
- określanie autorstwa tekstów literackich,
- wydobywanie nazw hoteli w ofertach turystycznych,
- predykcja kursów giełdowych na podstawie tekstów ekonomicznych,
- budowa systemu dialogowego dla użytkowników operatorów telefonicznych,
- konstrukcja chatbota dla petentów Urzędu Miejskiego Wrocławia,
- utworzenie wirtualnej sekretarki lekarza pierwszego kontaktu,
- wykrywanie mowy obraźliwej w komentarzach na Twitterze,
- streszczanie artykułów prasowych.

W każdym z wyżej wymienionych przypadków należy utworzyć tzw. korpus reprezentatywny dla danej dziedziny. Modele językowe powstałe z wielkich i ogólnych korpusów językowych można stosować do tego typu zadań, lecz często wcześniej dostraja się je (ang. fine-tuning) na korpusach wzorcowych. Z założenia korpusy wzorcowe mają pomóc w realizacji zadania, gdyż zawierają teksty z konkretnej dziedziny, zawierają specyficzne dla danego problemu słownictwo, określone konstrukcje leksykalno-składniowo-semantyczne i dzięki temu spodziewamy się poprawy jakości działania metody dostrojonej na takim korpusie.

## Część I

### Anotacja (5 pkt)

Należy wykonać anotację wybranego zbioru danych zgodnie z procedurą 2+1. W trakcie anotacji należy monitorować poziom zgodności (2 iteracje) oraz aktualizować wytyczne (po iteracji 1). W anotacji należy **posłużyć się zbiorami dostarczonymi w ramach instrukcji lub własnym zbiorem danych** (np. powiązany z projektem naukowo-wdrożeniowym).

### Plan realizacji ćwiczenia

1. Wczytać wybrany korpus tekstów i przygotować do anotacji [1pkt]
1. Ustalić wytyczne anotacji i wykonać anotację w wybranym narzędziu [1pkt]
  - a. Sugerowane narzędzie: **Label Studio** (<https://labelstud.io>), instalacja poleceniem `pip install label-studio`. Narzędzie obsługuje anotację zarówno całych tekstów, jak i fragmentów tekstu.
  - b. Alternatywnie: **Doccano** (<https://github.com/doccano/doccano>) lub Google Spreadsheets (tylko anotacja na poziomie całego tekstu).
  - c. Zapisać wytyczne w formie krótkiej notatki dla anotatorów
  - d. Anotacja przeprowadzona na poziomie całego tekstu
  - e. Anotacja na poziomie poszczególnych fragmentów tekstu
  - f. Należy pamiętać o dobrych praktykach anotacji (niezależność anotacji poszczególnych anotatorów, próbka dobrana losowo, itd.)
2. Wykonać eksport oetykietowanych danych i wyliczyć zgodność [0.5pkt]
  - a. Wyliczyć wartość Kappy Cohena

- b. Wyliczyć wartość Kappy Fleissa
- 3. Ustalić nowe wytyczne i powtórzyć anotację na nowej próbce danych [1pkt]
- 4. Ponownie wyliczyć zgodność i porównać z wart. z pierwszej iteracji [0.5pkt]
  - a. Wyliczyć wartość Kappy Cohena
  - b. Wyliczyć wartość Kappy Fleissa
- 5. Jeśli osiągnięto odpowiedni poziom zgodności, należy zaanotować pozostałą część zbioru (każda osoba anotuje po N niezależnych przykładów)
- 6. Zwięźle podsumować pozyskany zbiór za pomocą statystyk opisowych [1 pkt]

### Sugerowane zbiory danych

#### 1. Zbiór PolEmo

<https://clarin-pl.eu/dspace/handle/11321/710>

- Własną anotację można porównać z anotacją dostarczoną w ramach korpusu
- W ramach anotacji fragmentów tekstu sugeruje się wykonanie anotacji aspektów (ang. Aspect-based Sentiment Analysis) lub modyfikatorów wydźwięku na poziomie fraz (wzmacnianie, osłabianie, odwracanie polaryzacji)

#### 2. Detekcja mowy nienawiści

[https://huggingface.co/datasets/poleval/poleval2019\\_cyberbullying](https://huggingface.co/datasets/poleval/poleval2019_cyberbullying)

- Należy posłużyć się biblioteką *'huggingface datasets'*, aby wczytać zbiór.
- W ramach anotacji fragmentów tekstu sugeruje się wykonanie anotacji aspektów lub modyfikatorów opinii na poziomie fraz (wzmacnianie, osłabianie, odwracanie)

#### 3. Inne, własne zadania:

- emocje w komentarzach filmowych
- fake newsy i dezinformacja
- styl i autorstwo
- opinie pacjentów o lekarzach
- ...

### Sugerowana literatura

*Handbook of Linguistic Annotation*, Nancy Ide, James Pustejovsky, Springer, 2017;  
sugerowany artykuł: „Inter-Annotator Agreement” (s. 297)

Artykuł o anotacji wydźwięku (Sentiment):

<https://medium.com/besedo-engineering/sentiment-analysis-part-3-data-annotation-d0845d1a8a1b>

Artykuł o anotacji jednostek nazewniczych (NER)

<https://medium.com/@rongqianhui/named-entity-recognition-annotation-schemes-e684f9cd5a56>

*DiaBiz.Kom – Towards a Polish Dialogue Act Corpus Based on ISO 24617-2 Standard*,  
<https://aclanthology.org/2022.coling-1.320.pdf>

Dokumentacja Label Studio (szablony do klasyfikacji tekstu i NER)

<https://labelstud.io/templates>

Artykuł o Docanno

<https://towardsdatascience.com/doccano-a-tool-to-annotate-text-data-to-train-custom-nlp-models-f4e34ad139c3>

## Część II

Pre-trenowane modele przestrzeni wektorowych służą do modelowania różnorodnych zjawisk językowych występujących w korpusach tekstów. W niniejszej części należy zapoznać się z podstawowymi metodami tworzenia modeli przestrzeni wektorowych (model worka słów (ang. Bag-of-Words) i TF-IDF, Word2Vec, Fasttext) oraz ze współczesnymi enkoderami zdań opartymi na modelach transformerowych, a następnie zastosować je do analizy tekstów oraz ich anotacji. Należy zestawić rezultaty otrzymane za pomocą wybranych modeli osadzania i algorytmów redukcji wymiarowości danych z uzyskanymi w Części I anotacjami. Celem ćwiczenia jest wstępna analiza oetykietowanych danych oraz weryfikacja ich przydatności do automatycznego przetwarzania za pomocą prostych klasyfikatorów.

### Plan realizacji ćwiczenia

#### Word Embeddings (2 pkt)

1. Wykonać osadzenia słów w anotowanym korpusie (co najmniej 2 różne modele) [0.5pkt]
  - a. Word2vec
    - i. dla języka polskiego:

<https://dsmodels.nlp.ipipan.waw.pl>

b. Fasttext

i. dla języka polskiego:

<https://huggingface.co/clarin-pl/fastText-kgr10>

2. Wizualizacja danych za pomocą t-SNE (lub UMAP) z odniesieniem do etykiet w ramach anotacji. Wykonać wykres interaktywny, w którym po najechaniu na punkt można odczytać słowo i / lub anotację. [0.5pkt]
3. Wygenerować listy k-najbardziej podobnych dla słów zaanotowanych w korpusie i porównać otrzymane listy dla co najmniej 2 różnych modeli przestrzeni wektorowych [0.5pkt]
4. Opracować krótką dyskusję otrzymanych rezultatów [0.5pkt]

**Pytania pomocnicze do dyskusji:**

1. Czy osadzenia pre-trenowane na dużych korpusach dobrze odwzorowują znaczenie słów w utworzonym korpusie dziedzinowym?
2. Czy w zebranych korpusie tekstowym występuje grupowanie słów związanych z anotacją?
  - Przykładowo, w kontekście wydźwięku, czy występuje grupowanie na słowa pozytywne i negatywne? Jeśli nie, to dlaczego osadzenia mogą nie oddawać emocjonalnego znaczenia słów?
3. Na czym polegają różnice między wygenerowanymi za pomocą różnych modeli listami podobieństwa i z czego one wynikają?
4. Jak moglibyśmy ulepszyć osadzenia dla rozwiązywanego zadania?

**Text Embeddings: modele statyczne a kontekstowe (1.5 pkt)**

1. Wygenerować osadzenia zdań lub całych tekstów za pomocą dwóch modeli: [0.5pkt]
  - a. model statyczny: uśrednione wektory Word2Vec lub wektory zdań Fasttext (można wykorzystać modele z punktu Word Embeddings),
  - b. współczesny enkoder zdań z biblioteki SentenceTransformers (<https://sbert.net>), np.:
    - i. sdadas/mmlw-roberta-base:  
<https://huggingface.co/sdadas/mmlw-roberta-base>
    - ii. intfloat/multilingual-e5-base:  
<https://huggingface.co/intfloat/multilingual-e5-base>
    - iii. należy zapoznać się z kartą modelu, ponieważ część modeli wymaga dodania prefiksu do tekstu wejściowego.

2. Dla każdego z modeli, wizualizacja danych za pomocą t-SNE (lub UMAP) z odniesieniem do etykiet w ramach anotacji. Wykonać wykresy interaktywne, w których po najechaniu na punkt można odczytać zdanie (tekst) i / lub anotację. [0.5pkt]
3. Proszę przeprowadzić analizę otrzymanych osadzeń, porównać model statyczny z enkoderem kontekstowym i odpowiedzieć na zadane pytania pomocnicze (patrz poniżej). [0.5pkt]

### Pytania pomocnicze do dyskusji

1. Czy są zdania, które model uznał za podobne, ale w rzeczywistości różnią się znaczeniem (np. tylko negacją)?
2. Czy są zdania, które są semantycznie podobne, ale model uznał je za odległe, bo użyto innych słów?
3. Czy zdania o różnej długości, ale podobnym sensie, są traktowane przez model podobnie? Czy długość tekstu wpływa na „wyrazistość” jego wektora (szczególnie przy uśrednianiu wektorów słów)?
4. Który z modeli lepiej separuje klasy z anotacji i dlaczego?

Proszę uzasadnić swoje odpowiedzi.

### Klasyfikacja: przydatność zbioru do automatycznego przetwarzania (1.5 pkt)

Na zaanotowanym zbiorze (etykiety na poziomie całego tekstu) należy wytrenować proste klasyfikatory i zweryfikować, czy zebrane dane umożliwiają automatyczne rozpoznawanie etykiet. **Uwaga: w tym zadaniu nie należy dostrajać modeli transformerowych**, dostrajanie jest przedmiotem Zadania 2.

1. Wytrenować i porównać klasyfikatory (np. regresja logistyczna) na różnych reprezentacjach tekstu: [0.5pkt]
  - a. TF-IDF (Bag-of-Words),
  - b. osadzenia z modelu statycznego,
  - c. osadzenia z enkodera zdań.
2. Porównać wyniki z lematyzacją i bez lematyzacji tekstu: [0.5pkt]
  - a. porównanie należy wykonać co najmniej dla TF-IDF oraz modelu statycznego (Word2Vec / Fasttext),
  - b. do lematyzacji można wykorzystać np. spaCy (pl\_core\_news\_lg), Morfeusz2 lub Stanza,

- c. należy zwrócić uwagę, czy wybrany model Word2Vec został wytrenowany na formach słów, czy na lematach.
3. Opracować wyniki i dyskusję: [0.5pkt]
- a. ewaluacja z użyciem walidacji krzyżowej (lub wydzielonego zbioru testowego) z zachowaniem rozkładu klas (stratyfikacja),
  - b. miary: accuracy oraz macro-F1, macierz pomyłek,
  - c. analiza przykładowych błędów klasyfikacji w odniesieniu do przypadków spornych z anotacji (Część I).

### Pytania pomocnicze do dyskusji

1. Jak lematyzacja wpływa na rozmiar słownika i na skuteczność TF-IDF? Dlaczego w języku polskim efekt ten może być silniejszy niż w języku angielskim?
2. Czy lematyzacja pomaga modelom statycznym? Czy Fasttext (n-gramy znakowe) jest na nią mniej wrażliwy niż Word2Vec?
3. Dlaczego lematyzacja nie jest zwykle stosowana przy enkoderach transformerowych?
4. Czy prosta reprezentacja TF-IDF jest konkurencyjna wobec enkodera zdań? Z czego to wynika?
5. Czy przykłady, na których myli się klasyfikator, pokrywają się z przykładami, przy których anotatorzy byli niezgodni?

Proszę uzasadnić swoje odpowiedzi.

### Sugerowana literatura

#### 1. Wprowadzenie do Word Embeddings

Fragment książki D. Jurafsky o modelach przestrzeni wektorowych

<https://web.stanford.edu/~jurafsky/slp3/6.pdf>

Notatki do wykładu NLP, Stanford CS224N

[https://web.stanford.edu/class/cs224n/readings/cs224n\\_winter2023\\_lecture1\\_notes\\_draft.pdf](https://web.stanford.edu/class/cs224n/readings/cs224n_winter2023_lecture1_notes_draft.pdf)

Efficient Estimation of Word Representations in Vector Space

<https://arxiv.org/pdf/1301.3781>

*Distributed Representations of Words and Phrases and their Compositionality*

<https://arxiv.org/abs/1310.4546>

*Bag of Tricks for Efficient Text Classification*

<https://arxiv.org/pdf/1607.01759>

## 2. Eksploracja modeli przestrzeni wektorowych

Tutorial do ćwiczeń z NLP, Stanford

[https://web.stanford.edu/class/cs224n/assignments/a1\\_preview/exploring\\_word\\_vectors.html](https://web.stanford.edu/class/cs224n/assignments/a1_preview/exploring_word_vectors.html)

Algorytm klasteryzacji HDBSCAN

[https://hdbscan.readthedocs.io/en/latest/how\\_hdbscan\\_works.html](https://hdbscan.readthedocs.io/en/latest/how_hdbscan_works.html)

Redukcja wymiarowości za pomocą t-SNE

<https://medium.com/@sachinsoni600517/mastering-t-sne-t-distributed-stochastic-neighbor-embedding-0e365ee898ea>

Redukcja wymiarowości za pomocą UMAP

[https://umap-learn.readthedocs.io/en/latest/how\\_umap\\_works.html](https://umap-learn.readthedocs.io/en/latest/how_umap_works.html)

## 3. Enkodery zdań

Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks

<https://arxiv.org/abs/1908.10084>

Dokumentacja SentenceTransformers

<https://sbert.net>

Polskie modele MMLW i benchmark PL-MTEB

<https://arxiv.org/abs/2402.13350>

## 4. Lematyzacja dla języka polskiego

spaCy: modele dla języka polskiego

<https://spacy.io/models/pl>

Morfeusz2

<http://morfeusz.sgi.jp.pl>